

刘雅秀

电话：13931198068（微信同号） | 邮箱：sylvia3337@163.com | 2027届

- 产品经理方向：聚焦 AI Agent、RAG、LLM 评测、信贷交易链路与电商支付场景，擅长把模糊技术问题拆成可定义、可协同、可评测的产品机制，并推动落到业务指标。
- 个人优势：能在复杂项目中主动完成问题归因、策略拆解、规则设计、跨团队对齐与评测闭环，不只交付页面或需求文档，更关注机制是否能长期复用。

教育经历

- 清华大学（硕士） – 电子信息 2024.09 – 2027.06
- 河北大学（本科） – 生物信息 2020.09 – 2024.06
- 荣誉奖项：全国大学生自强之星、校特等奖学金（1%）、挑战杯国家级特等奖、中国日报社英语写作全国一等奖、“互联网+”国家级三等奖、“京津冀-粤港澳”创业大赛国家优胜奖、腾讯“2025 LIGHT创造营”优秀项目、HICOOL 青年创业梦想计划梦想新星奖。

实习经历

- 腾讯 – 云产品六部 WorkBuddy 技术产品 2026.04 – 2026.06

主要工作：围绕 WorkBuddy Agent 的 harness、工具调用、上下文注入与 MCP 插件链路，将“工具越来越多但模型用不好”的问题抽象为上下文治理与能力路由问题，设计平台化机制提升工具路由准确性、上下文可控性、会话稳定性与工程可扩展性。

【Agent 工具架构重构】

- 将工具集膨胀带来的 Token 浪费、注意力稀释和误调用问题重新定义为“Agent 如何按任务理解工具能力”的产品问题，拆解出工具理解、候选召回、上下文注入、调用兜底四个关键环节，而不是只做工具列表优化。
- 产出 Deferred 工具延迟加载方案和 ToolSearch 动态路由规则，定义工具描述字段、触发条件、渐进式加载策略和兜底匹配逻辑，把原本静态堆叠的工具上下文改造成可搜索、可治理、可扩展的能力索引。
- 通过这套机制降低无效上下文占用和高频误调风险，让 Agent 在复杂工具环境中具备按需理解、按需调用和可持续扩展的能力，并为后续多工具 harness 编排提供统一产品框架。

【MCP 高可用架构】

- 将 MCP 插件接入中的上下文注入混乱、会话内无法动态增删 Server、断连恢复弱等问题，抽象为“插件生命周期管理 + 会话稳定性”的平台能力，明确接入、加载、缓存、恢复、退出各状态的产品边界。
- 设计会话级热加载机制和“快缓存-自恢复-防循环”连接模型，补齐按需过滤、本地缓存、异常隔离、重连兜底等规则，使插件异常不再直接干扰 Agent 主链路。
- 最终推动外部插件从静态硬编码接入升级为动态可管理能力，提升 Agent 上下文可控性、插件可用性和异常场景稳定性。

- 京东科技 – 产品经理 | 白条交易 2026.01 – 2026.04

主要工作：负责白条交易链路中的信贷产品增长与电商支付场景渗透，从用户理解、权益表达、链路承接和 A/B 评测四个层面推动关闭挽留与购物车-结算-收银台优惠联动，提升交易转化、白条支付渗透与分期收入。

【AI 挽留助手】

- 针对免息优先付 3.64% 的关闭率，结合埋点和用户反馈将流失原因从“用户不需要权益”重新归因为“控制感丧失”和“500 元起分门槛误解”，据此把挽留目标从强拦截改为解释权益、诊断顾虑并帮助用户调整设置。
- 设计 E-D-D（共情-诊断-化解）对话模型和 RAG 动态追问链路，沉淀关闭原因识别、知识库召回、工具触发和结果反馈规则，并接入“修改起分金额”等工具能力，使 AI 助手能直接解决用户问题而非只做话术劝返。
- 上线后建立埋点监控与 bad case 评测闭环，用真实失败样本反哺知识库和对话策略迭代，带来日均分期交易额增量 3000w+、日收入增量 90w。

【购物车支付优惠联动】

- 发现白条权益在站购购物车阶段表达缺失，用户到收银台才感知优惠，导致信贷支付价值没有进入加购和结算决策；据此将项目目标定义为把白条权益前置到购物车并贯穿结算、收银台全链路。
- 拆解购物车、结算、收银台三个触点的用户决策差异，制定 6 类权益展示策略、品类/客群推荐规则和试金石 A/B 实验方案，并协调科技侧支付准入、molo 智能决策与交易侧结算复用改造，确保权益表达和交易承接一致。
- 上线后日均成交增量约 1 万单，转化率从 3.4% 提升至 3.7%，沉淀出“权益前置-链路承接-实验评测”的电商信贷增长方法，可复用于其他支付权益场景。

深圳深度赋智科技有限公司（MetaGPT Agent） – AI 产品实习生

2025.06 – 2025.09

主要工作：负责 Deep Research Agent 的评测体系、决策策略与报告生成流程优化，将“答案不稳定”拆解为 Query 生成、搜索决策、信息抽取、答案整合和报告结构多个可定位环节，推动复杂研究任务准确率和报告稳定性提升。

【Deep Research 评测与决策优化】

- 面对 Deep Research 准确率和稳定性不足的问题，主动把评测目标从“最终答案对错”前移到“链路损耗定位”，建立能复现、能归因、能指导策略迭代的评测框架。
- 引入 GAIA/xBench 与 LLM-as-a-Judge，设计失败 case 链路溯源方法，将问题拆到 Query 生成、搜索决策、信息抽取和答案整合等环节，定位约 50% 损耗来自 Query 生成，避免团队只在最终答案层面反复调 prompt。
- 基于评测结论提出分层解析模板、置信度动态搜索策略与中间状态模块，把诊断结果转化为可实现的产品策略，将 xBench 准确率由 55% 提升至 60%。

【流程、Prompt 与竞品评测】

- 针对报告生成停留在段落级拼接、增量修改不稳定的问题，将生成流程升级为 Section 级结构化链路，定义模块拆分、上下文继承和差异化 Prompt 策略，提升报告的可控性和多轮修改稳定性。
- 定义增量交互指标体系和核心人群研究场景，构建可复用评测案例集，并对 Genspark 等竞品进行 LLM-as-a-Judge 多维评分，为产品差距判断提供量化依据。
- 评测结果明确了我方产品在交互增量、报告结构和任务边界上的短板，为后续模型策略、Prompt 迭代和产品定位提供决策依据。

科研经历

OScaR: The Occam's Razor for Extreme KV Cache Quantization in LLMs and Beyond (NeurIPS 在投, CCF-A)

2026.03 – 2026.05

- 揭示 TNI 是 KV Cache 量化瓶颈，提出由分流旋转与全 Token 缩放组成的轻量通用量化框架，实现近乎无损的 INT2 缓存压缩。

Attention Sink in Transformers (arXiv:2604.10098, Computer Science Review SCI 一区在投)

2026.01 – 2026.04

Journal of Chromatography A (JCR 一区)

2022.03 – 2022.10

基于 RAG 的医疗问诊助手、人际关系管理系统 (vibecoding)、自动化投递简历系统 (OpenClaw)

2024.10 – 至今

创业经历

脊柱侧弯康复 AI 评估的技术研究 – CEO

2024.12 – 2025.12

- 将脊柱侧弯居家评估从“用户拍照 + 算法识别”的粗流程拆成「拍摄引导-质量校验-自动评估-结果解读」四个产品模块，降低非专业用户的拍摄门槛，并让评估结果可解释、可交付。
- 围绕居家场景中姿态、距离和拍摄质量不稳定的问题，推进 YOLOv8 自适应脊柱关键点检测，引入 CSPNet 与 PAN-FPN 多尺度特征融合，并融合脊柱曲率切点与肩胛几何特征的双模态评估算法；关键点检测 mAP@0.5:0.95 = 94.4%，单目测距误差控制至 7.2%。
- 获得朝阳区首批数字疗法 50 万元孵化资金、腾讯 LIGHT 创造营优秀项目（最高奖项）、HICOOL 青年创业梦想计划梦想新星奖等。

专业技能

- 产品/工具：Vibecoding (Cursor、Claude、Codex)、Figma、Axure、Adobe Photoshop、Excel (数据透视表、VLOOKUP)、SQL。
- AI 技术栈：熟悉 RAG 链路、LangChain、Prompt Engineering、OpenClaw、N8N；理解 LLM、VLM、VLA、世界模型及 Agent 工具调用/上下文工程。